



caractéristiques à 10000 mots afin de réduire l'espace mémoire nécessaire tout en conservant une diversité de termes suffisante pour le modèle. Les stopwords ont été supprimés lors de la vectorisation pour éviter que les mots les plus fréquents mais peu informatifs (comme "the", "and", "is") n'affectent le modèle. La matrice finale est creuse, ce qui permet de mieux gérer la mémoire, car tous les tweets ne contiennent pas les 10000 mots choisis.

Concernant la modélisation, trois modèles de classification ont été évalués : Naive Bayes, Régression Logistique, et SVM (Support Vector Machine). Leurs performances ont été mesurées via des métriques clés telles que la précision, le rappel et le F1-score, qui permettent d'évaluer respectivement la justesse des prédictions, la capacité à détecter toutes les instances positives et l'équilibre entre précision et rappel. Nous allons étudier les résultats de chacun des modèles ci dessous :

Naive Bayes : Avec une précision globale de 76.10%, ce modèle montre un bon équilibre entre les classes positives et négatives, atteignant un F1-score de 76% pour les deux classes. Cependant, il est limité face à des tweets ambigus ou contenant des expressions complexes.

Régression Logistique : Ce modèle dépasse Naive Bayes avec une précision de 76.99%. Il est particulièrement performant pour détecter les tweets positifs (rappel de 80%) tout en maintenant un F1-score équilibré. Cependant, il est légèrement moins efficace sur les tweets négatifs, avec un rappel de 73%.

SVM (Support Vector Machine) : Offrant une précision de 76.92%, ce modèle rivalise avec la régression logistique et est très efficace dans la détection des tweets positifs (rappel de 81%). Il maintient un bon équilibre global, mais demande plus de ressources pour l'entraînement.

Ensuite, au sujet des problèmes techniques avec les dépendances, il y a eu des difficultés liées à l'installation des bibliothèques nécessaires à l'exécution des algorithmes, notamment des erreurs liées à des versions incompatibles de bibliothèques comme scikit-learn et scipy. Même si les classes sont relativement équilibrées, il y a un petit déséquilibre qui peut affecter les performances du modèle, en particulier pour les classes moins représentées.

Il y a tout de même des pistes d'amélioration, l'utilisation de modèles plus avancés comme les réseaux neuronaux pourrait améliorer les résultats. L'utilisation de techniques comme GridSearchCV ou RandomSearchCV permettrait d'optimiser les hyperparamètres des modèles pour améliorer leur performance globale, ou encore des techniques plus avancées de traitement du texte, comme l'utilisation de représentations de mots pré-entraînées (par exemple Word2Vec ou GloVe). Enfin l'utilisation de techniques d'équilibrage des classes, comme SMOTE (Synthetic Minority Over-sampling Technique), pourrait également améliorer les résultats en compensant le léger déséquilibre dans les classes.

Pour conclure, les modèles atteignent une précision de 76-77%, avec de bonnes performances pour les tweets positifs; pour aller plus loin, il faut explorer des réseaux neuronaux et optimiser les hyperparamètres.

